

Probabilistische Vorhersagen relevanter Energiesystemvariablen mittels Generative AI

|EWT 2025

Verena Alton (verena.alton@ait.ac.at)

Peter Widhalm, Stefan Strömer, Lukas Exl

Förderhinweis

Dieses Projekt wird im Rahmen der Ausschreibung 2023 von „**AI for Green**“ des Bundesministeriums für Klimaschutz, Umwelt, Energie, Mobilität, Innovation und Technologie (BMK) durchgeführt. Die Abwicklung erfolgt im Auftrag des BMK durch die Österreichische Forschungsförderungsgesellschaft (FFG). Das Projekt wird im Rahmen des Themas Digitale Technologien, eine Initiative des BMK, unter der Fördervertragsnummer FO999910239 gefördert. Die Autoren geben an, dass kein Interessenkonflikt besteht. Die Geldgeber spielten keine Rolle bei der Gestaltung der Studie; bei der Sammlung, Analyse oder Interpretation von Daten; beim Verfassen der Texte oder bei der Entscheidung, die Ergebnisse zu veröffentlichen.

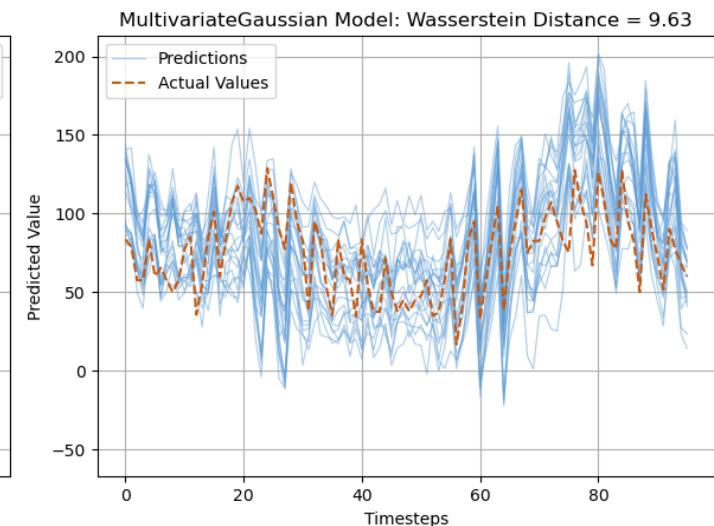
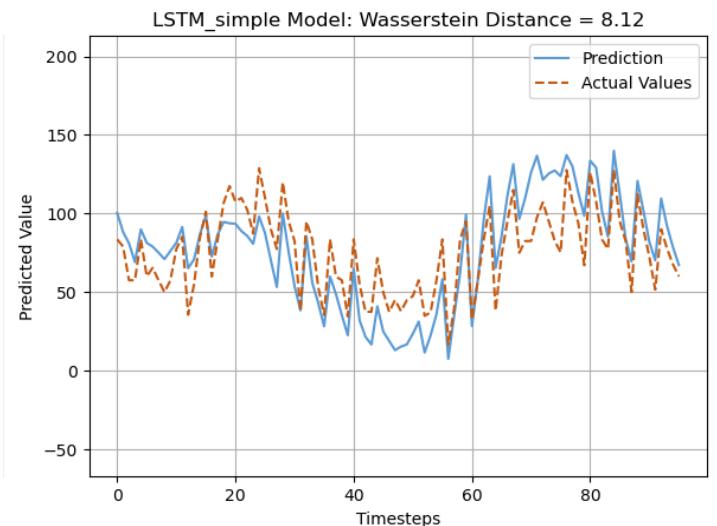
Motivation

Problem

Optimierung im Kraftwerksbetrieb benötigt genaue Prognosen relevanter Energiesystemvariablen (z.B. Strompreis)

Oft nur Punktprognosen vorhanden, obwohl probabilistische besser wären [Chai, 2024]

Predictions for 2024-07-11 (Thursday)



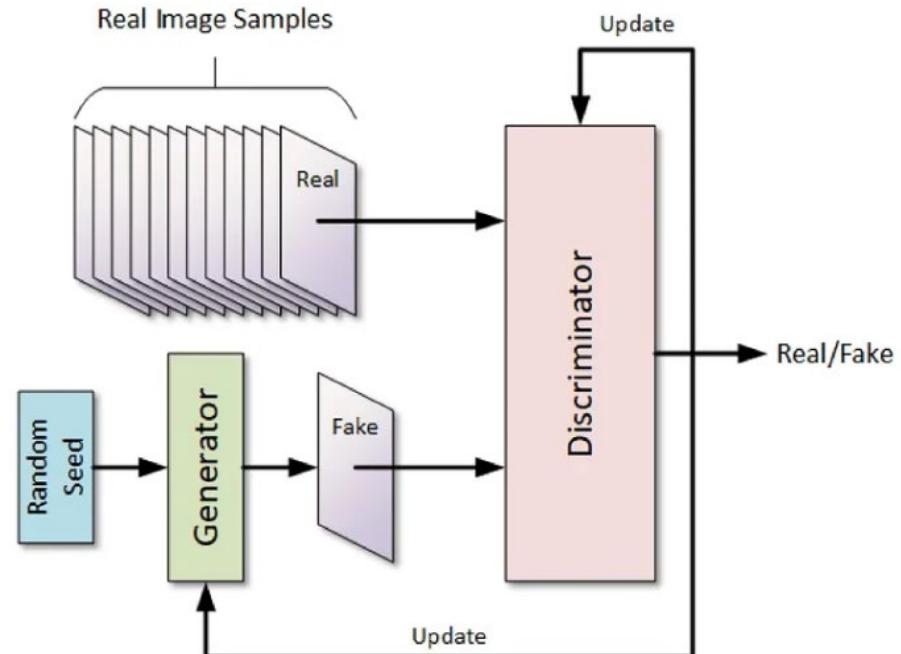
Motivation

Forschungsfragen

Können generative AI-Modelle präzise probabilistische Prognosen erzeugen?

Verbessern diese Prognosen die Optimierungsleistung im Vergleich zu State-of-the-Art-Prognosen?

GAN (Generative Adversarial Network)



Source: Medium.com [[Time Series Forecasting with GANs: A Comprehensive Guide | by Pape | Medium](#)]

Modelle

Baselines

"**ValsOfPrevDay**": Werte des Vortags

"**SARIMAX**

"**LSTM**": Long Short-Term Memory (deterministisches KI-Modell)

"**MVN**": Lineare Regression unter multivariater Normalverteilung

GAN-Modelle

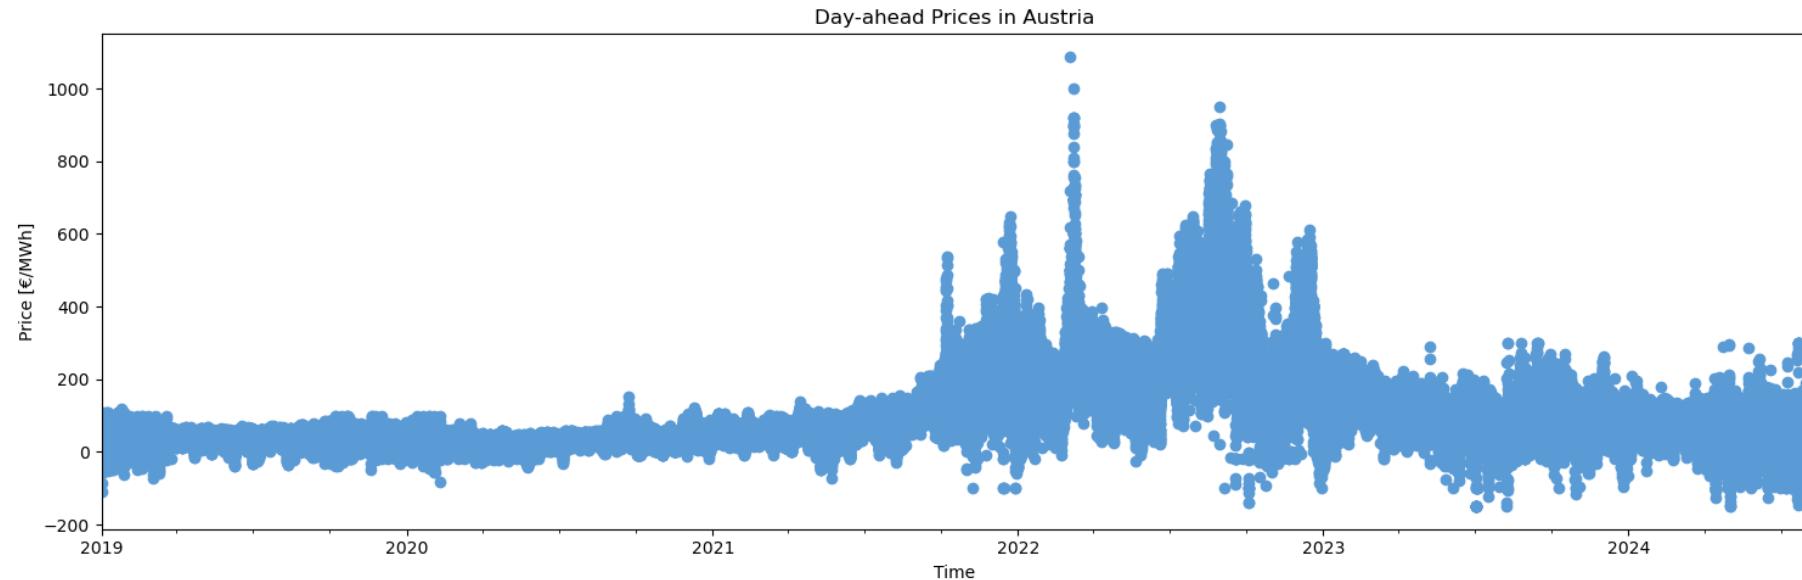
"**GAN-0**": Conditional Time Series GAN aus Literatur [[Lu, 2022](#)]

"**GAN-1**": cTSGAN mit eigenen Änderungen

"**GAN-2**": deterministische Prognose des LSTM; dann Vorhersage der Residuen durch cTSGAN

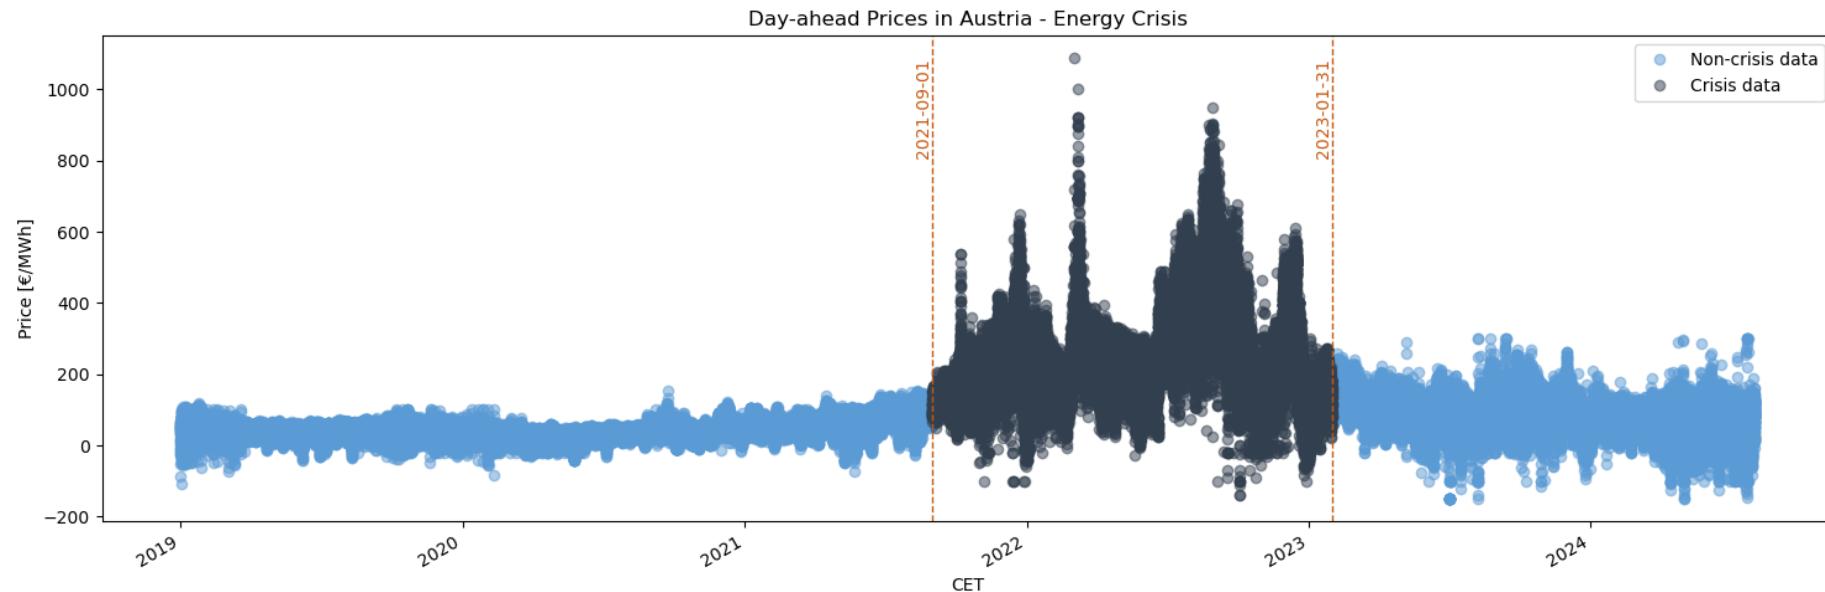
Daten

- Day-ahead Preise von 2019 bis Mitte 2024 [ENTSO-E transparency platform]



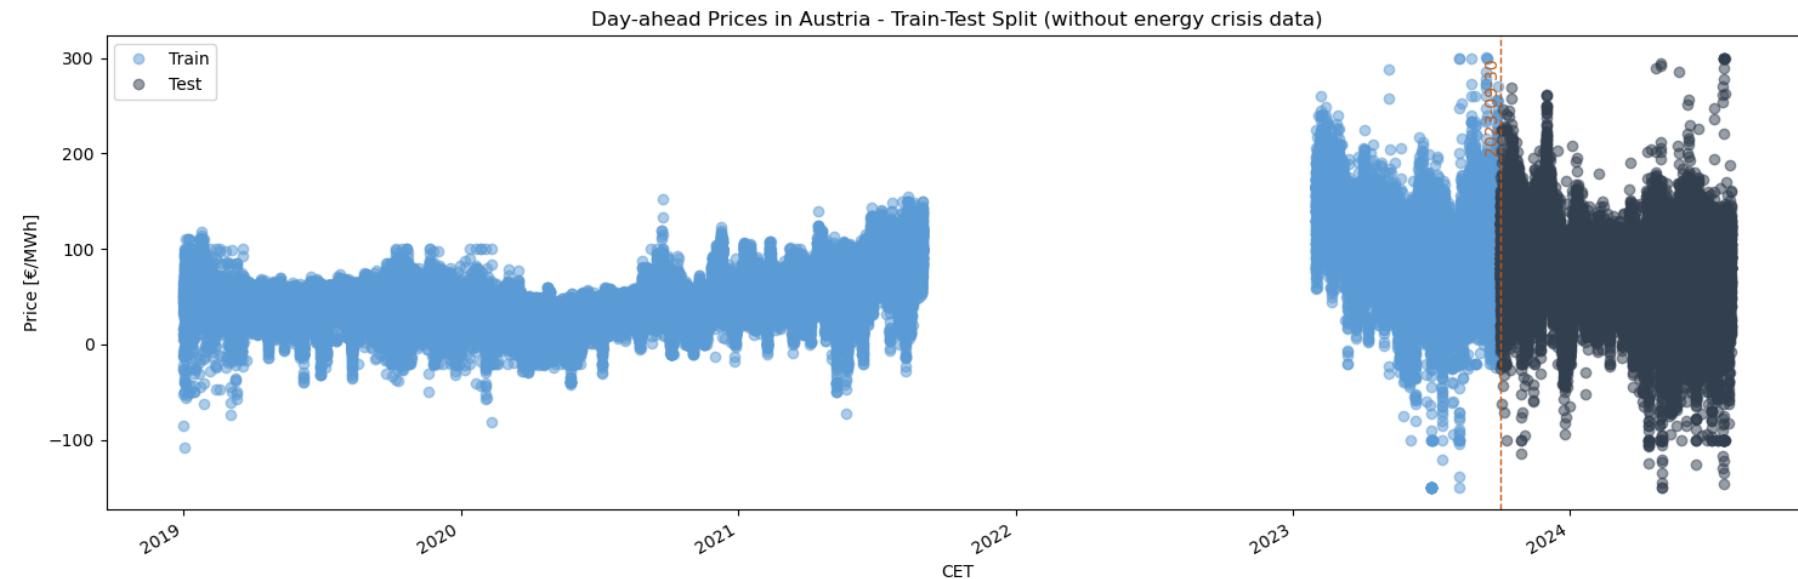
Daten: Energiekrise

- Day-ahead Preise von 2019 bis Mitte 2024 [ENTSO-E transparency platform]



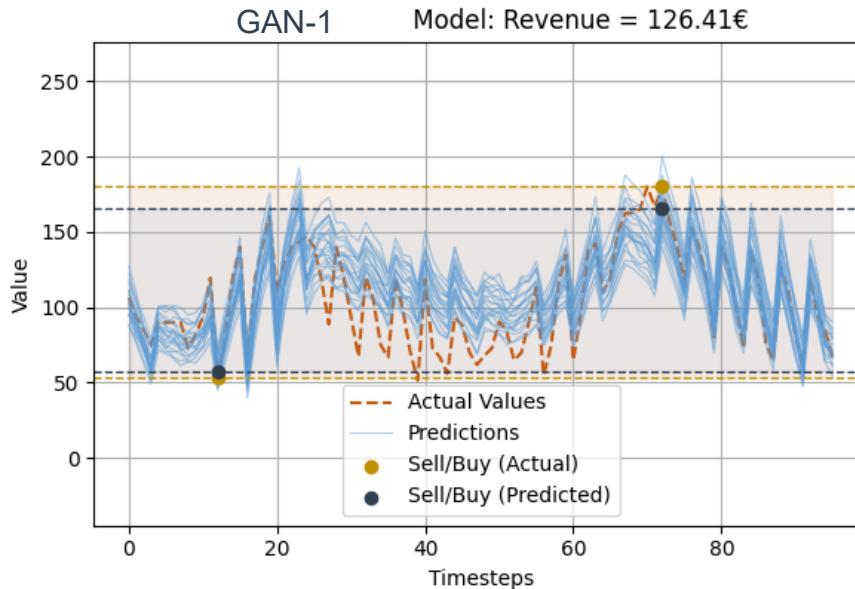
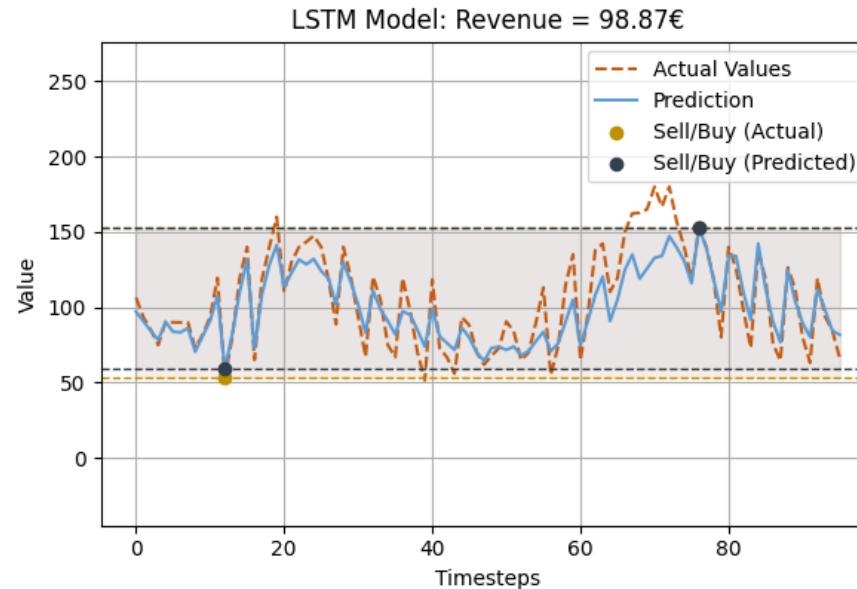
Daten: Train-Test Split

- Day-ahead Preise von 2019 bis Mitte 2024 [ENTSO-E transparency platform]



Evaluierung: Simplifizierte Optimierung

Predictions for 2023-09-06 (Wednesday)
Optimisation Strategy: Expectation

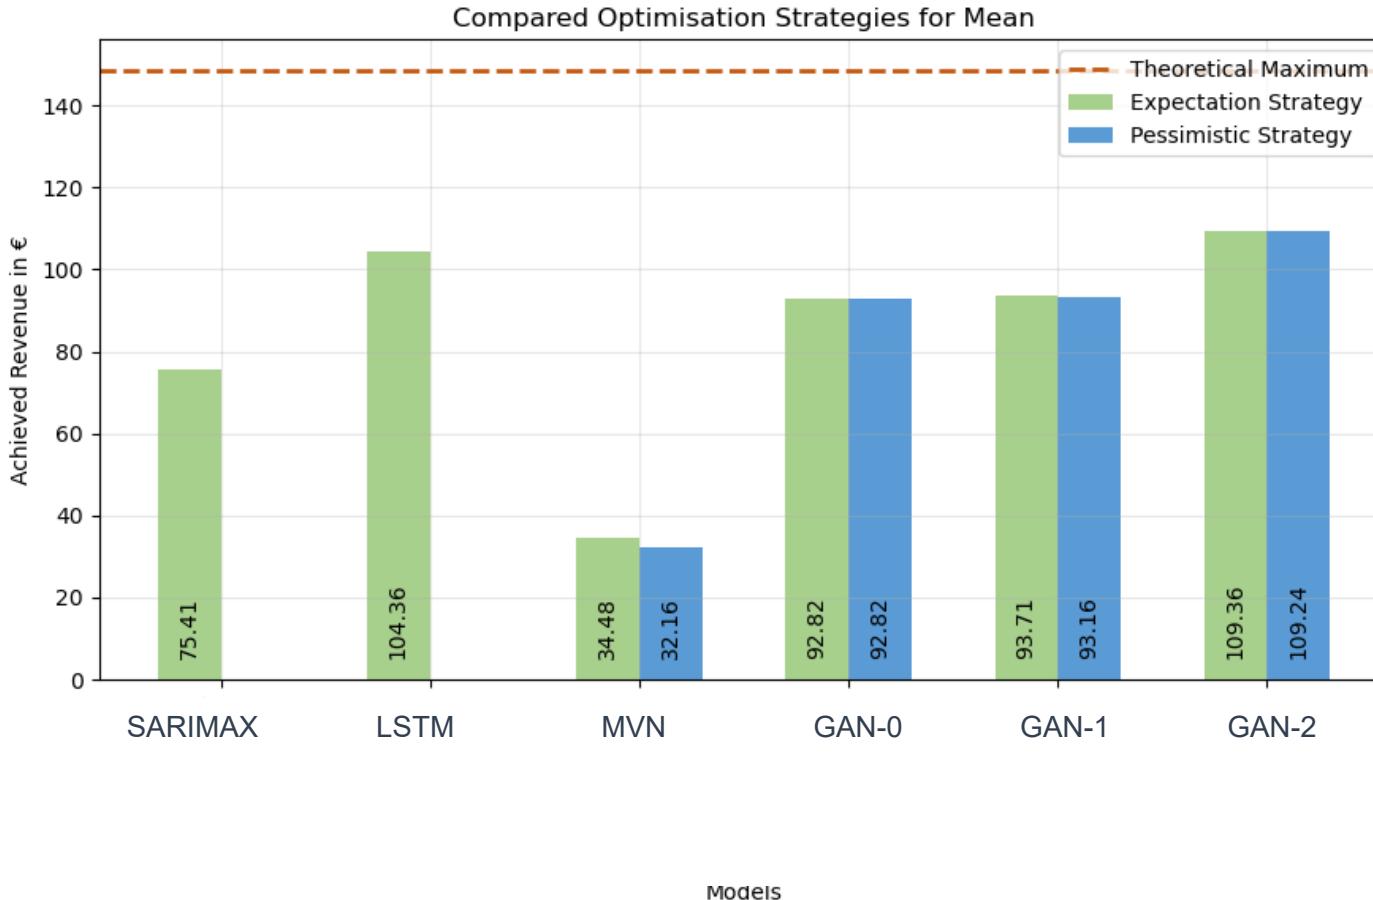


- $\Delta(t_1, t_2) = \text{Preis}_{\text{Prognose}}(t_1) - \text{Preis}_{\text{Prognose}}(t_2)$
- $(t_1, t_2) = \text{argmax}(\Delta(t_1, t_2))$
- Ertrag = Preis_{Tatsächlich}(t₁) - Preis_{Tatsächlich}(t₂)

Probabilistische Methoden können verschiedene Strategien verfolgen, z.B. niedriges Perzentil statt Mittelwert über Samples

Ergebnisse: Optimierung

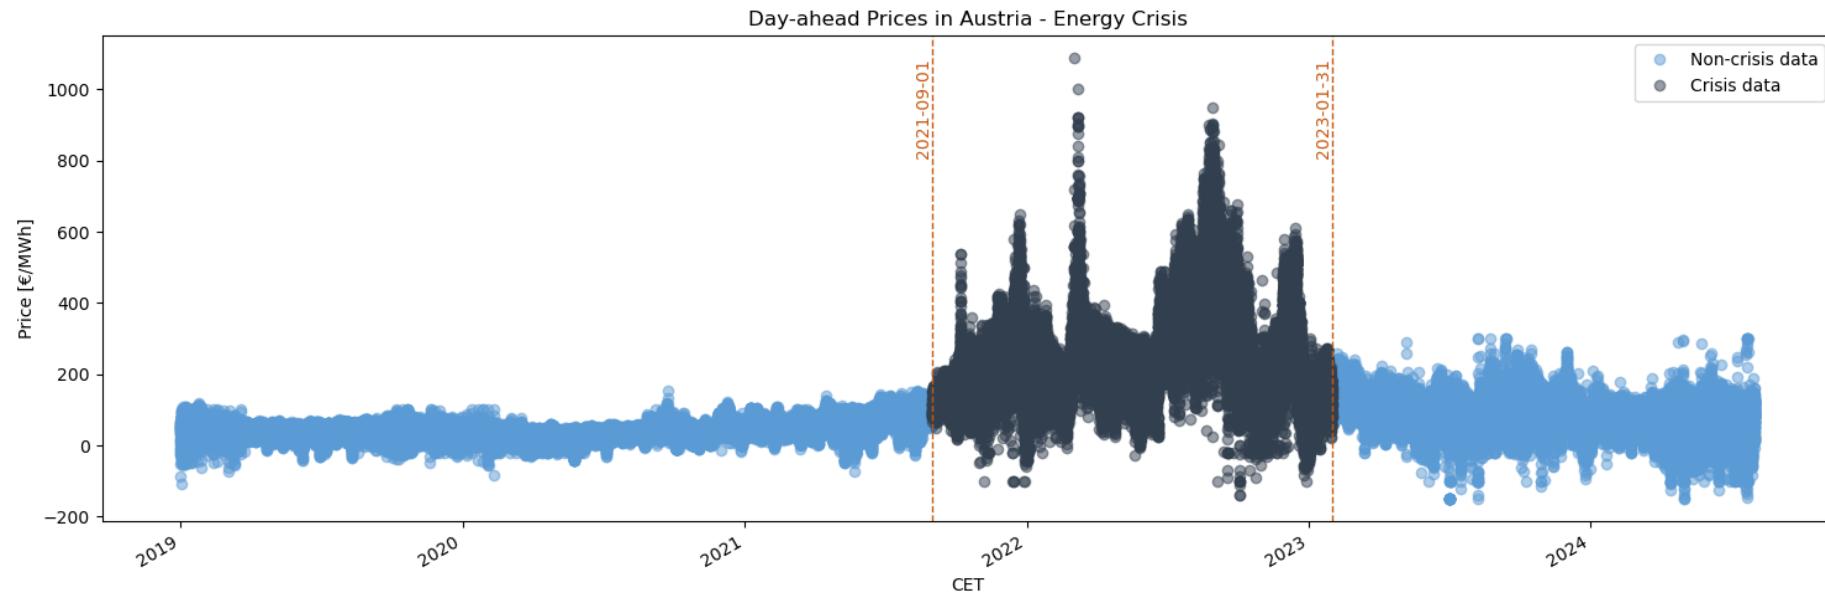
Mittelwert über alle Testdaten



- GANs performen ähnlich wie Punktschätzer
- Besser als probabilistische Baseline

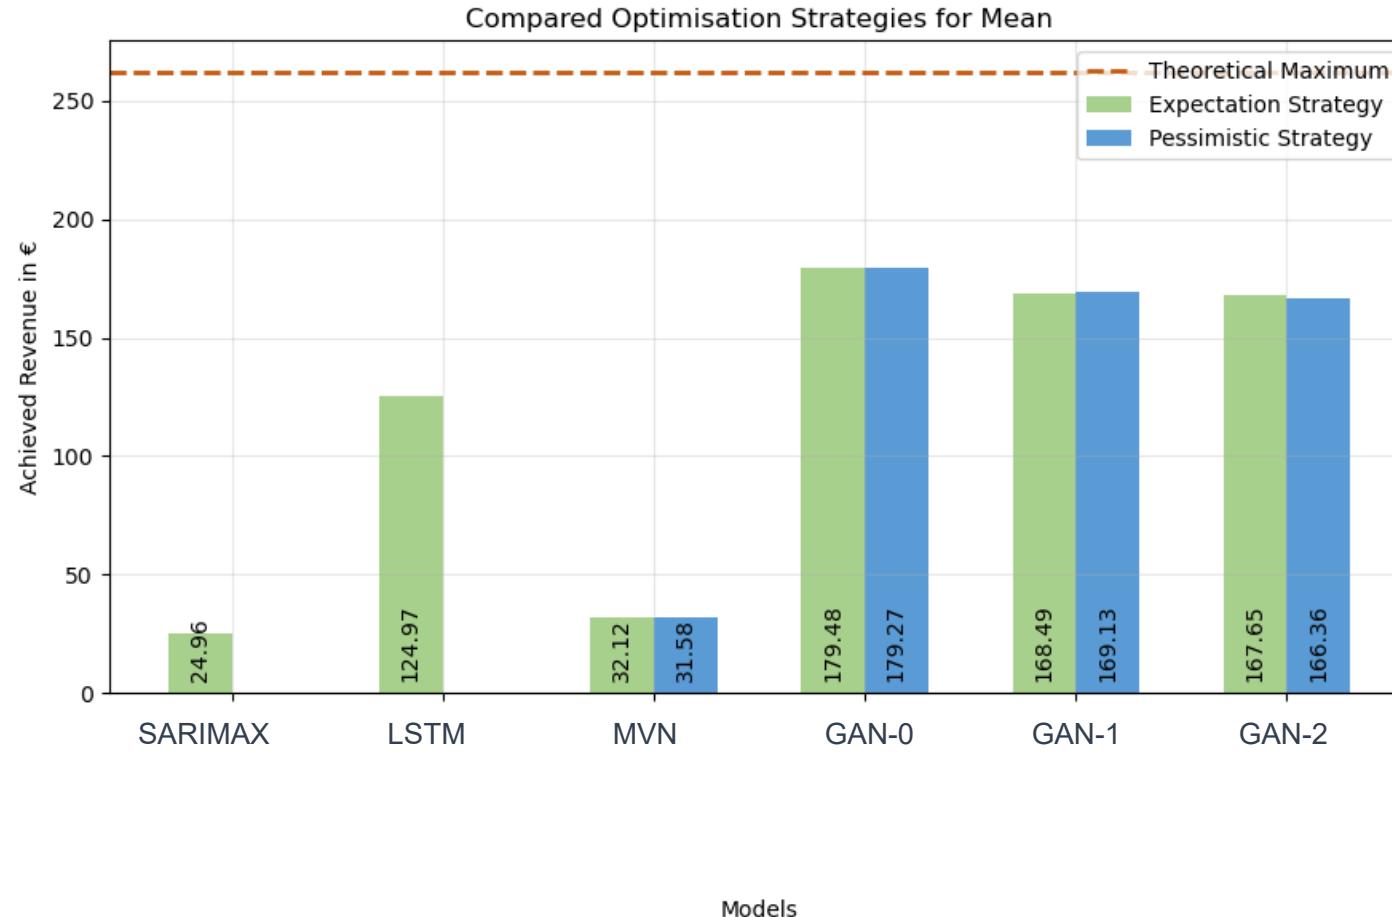
Daten: Energiekrise

- Day-ahead Preise von 2019 bis Mitte 2024 [ENTSO-E transparency platform]



Ergebnisse: Optimierung

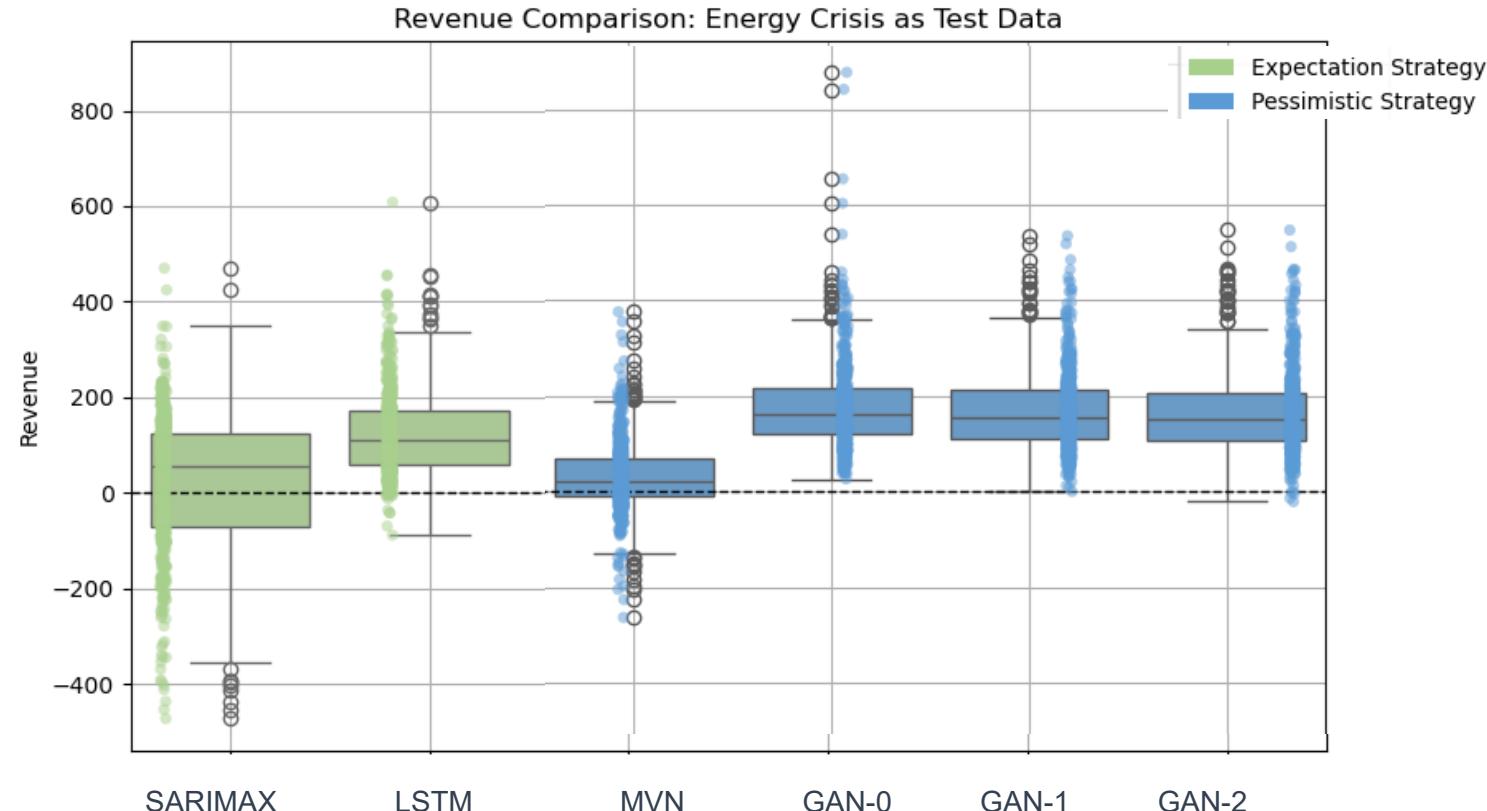
Energiekrise als Test-Daten



- GANs performen in ungewöhnlichen Szenarien deutlich besser

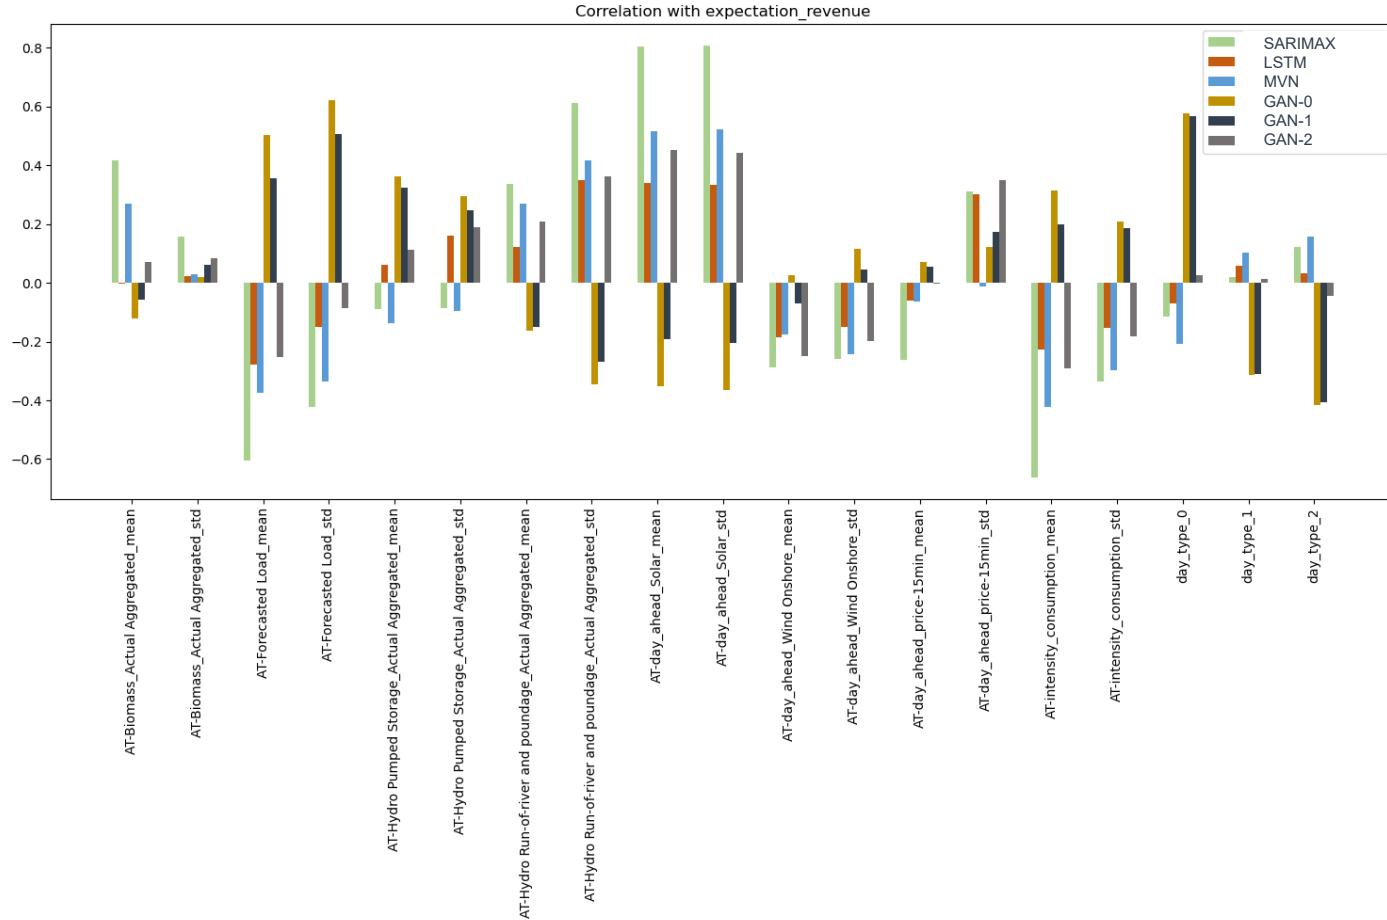
Ergebnisse: Optimierung

Energiekrise als Test-Daten



- GANs erzielen kaum/keine Verluste

Korrelationen: Optimierungsergebnisse mit Features



GANs performen bei Optimierung...

- besser:
 - an Tagen mit hoher Last und großen Lastschwankungen
 - an Werktagen
- schlechter:
 - bei viel Stromproduktion aus Fließkraftwerken und PV
 - an Wochenenden und Feiertagen

Ausblick

- Weitere generative AI-Modelle
- Weitere Zielvariablen:
 - CO₂-Intensität des Stromnetzes
 - Regelenergie-Abrufe
- Veröffentlichung der Live-Prognosen sowie des Codes auf transpAIrent.energy

Probabilistische Vorhersagen relevanter Energiesystemvariablen mittels Generative AI

IEWT 2025

Vielen Dank für Ihre Aufmerksamkeit!

Verena Alton (verena.alton@ait.ac.at)

Peter Widhalm, Stefan Strömer, Lukas Exl

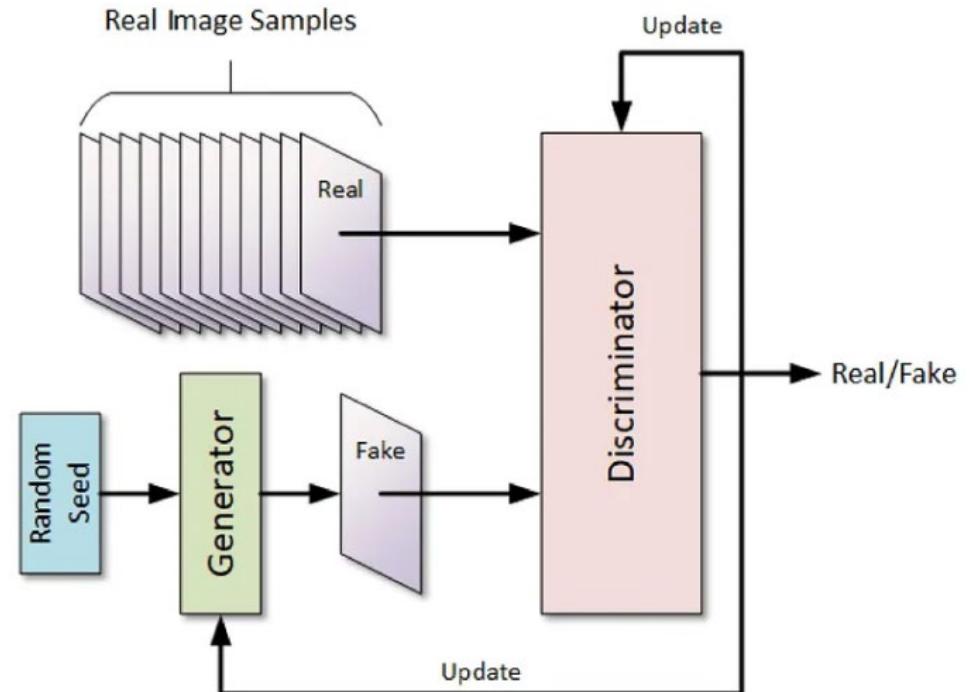


AI for Green – Ausschreibung 2023

Bundesministerium
Klimaschutz, Umwelt,
Energie, Mobilität,
Innovation und Technologie

GAN Modell

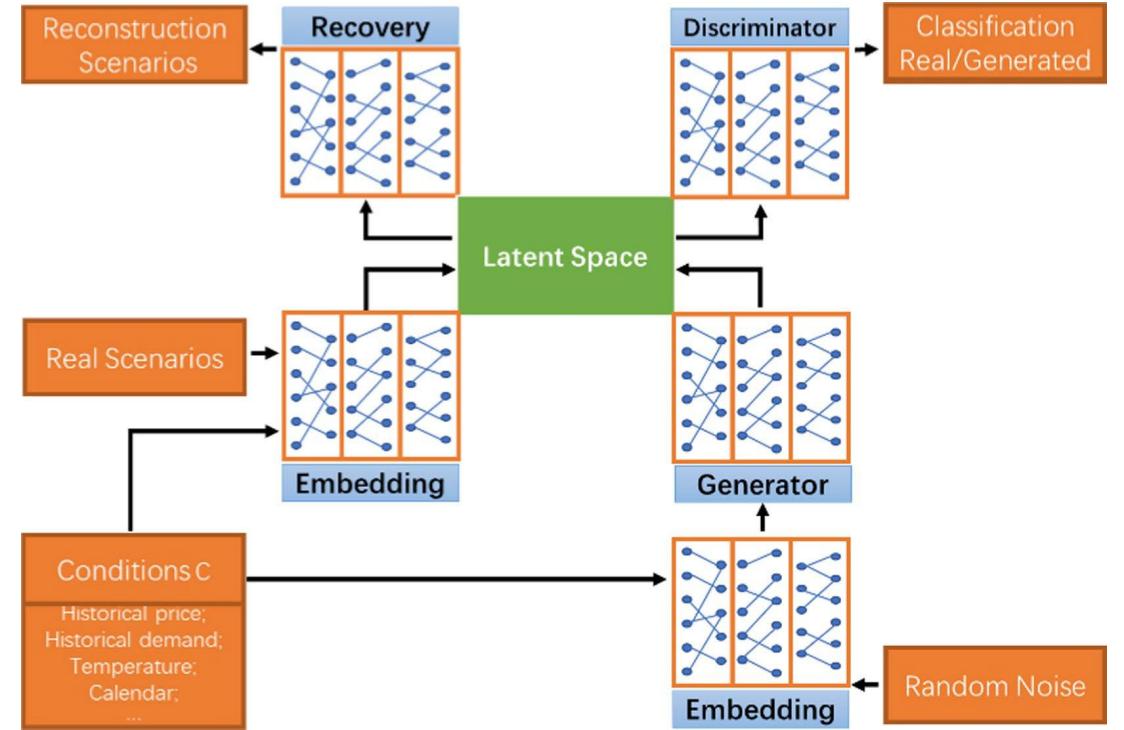
-  **Generative Adversarial Networks (GANs): ein generatives AI-Modell**
 - Ein **Generator** erstellt künstliche Daten (z. B. zukünftige Preis-Szenarien).
 - Ein **Diskriminator** unterscheidet echte von künstlichen Daten.
 - Durch diesen Wettbewerb werden die generierten Prognosen immer realistischer.
- Verschiedene Varianten
 - Original: Generative Adversarial Network [\[Goodfellow, 2014\]](#)
 - Conditional GAN
 - Wasserstein-GAN [\[Arjovsky, 2017\]](#)
 - Conditional Time Series GAN (cTSGAN) [\[Lu, 2022\]](#)
- Bekannte Probleme:
 - **Mode Collapse:** Generator spezialisiert sich auf wenige verschiedene Outputs -> keine richtige Verteilung
 - **Verschwindende Gradienten:** zu guter Diskriminator gibt nicht ausreichend Feedback
 - **Konvergenzproblem:** Feedback des Diskriminators wird weniger aussagekräftig mit der Zeit



Source: Medium.com [\[Time Series Forecasting with GANs: A Comprehensive Guide | by Pape | Medium\]](#)

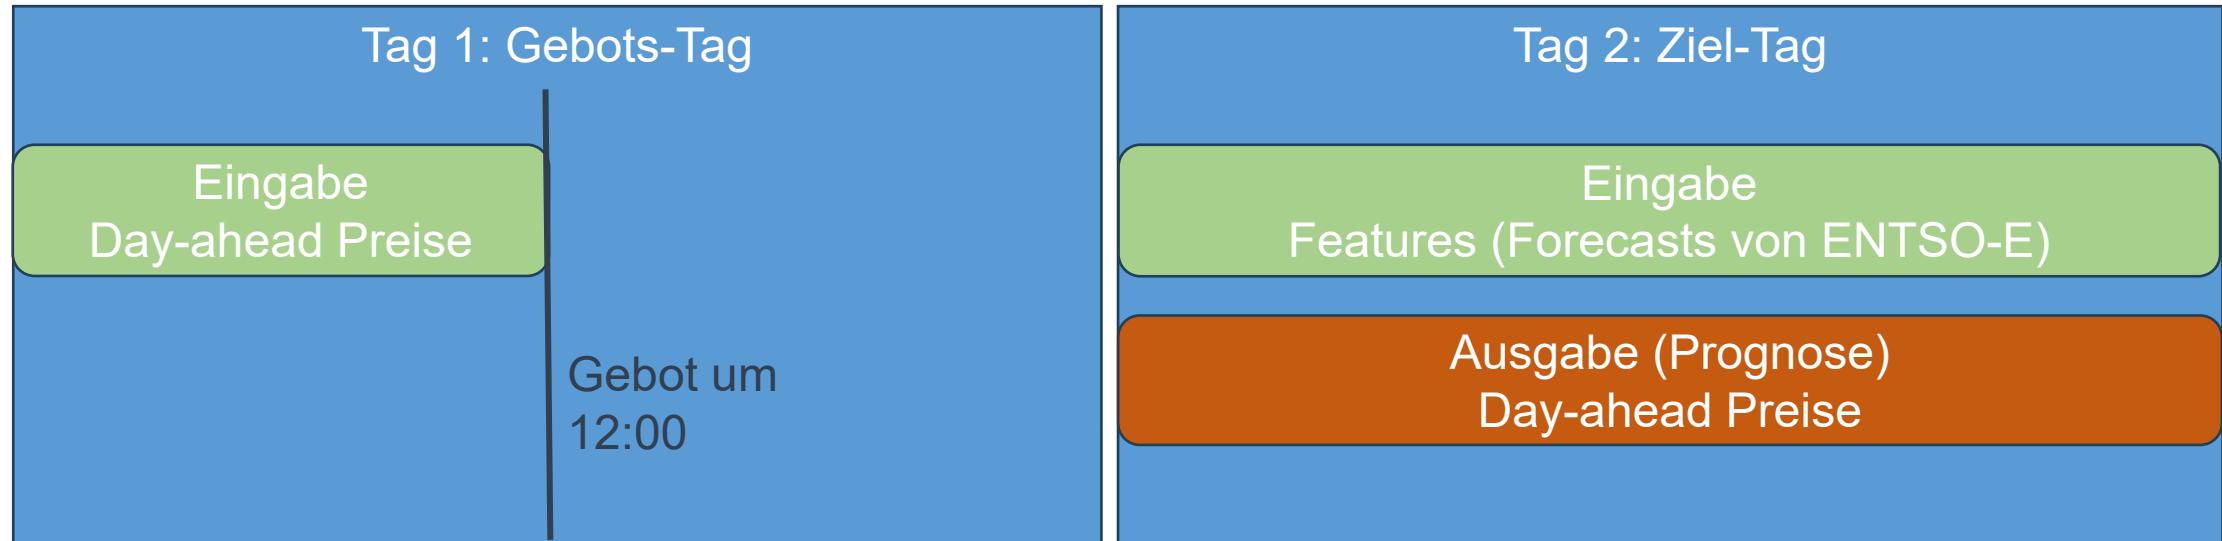
CTSGAN Modell

- LSTM-Layers um Zeitreihen-Eigenschaften einzufangen
- Zwei zusätzliche Netzwerke:
 - Embedding
 - Recovery
 --> Wettbewerb von Generator und Diskriminator findet in latenterem Raum statt
- 3 hintereinander ablaufende Trainings-Loops:
 - Embedding – Recovery
 - Embedding – Generator
 - Embedding – Generator – Diskriminator
- Eigene Anpassungen (cTSGAN_simple):
 - Embedding-Netz nicht dem Generator vorgeschaltet
 - *Gradient penalty* statt *weight clipping*
 - Weniger Epochen in dritter Trainings-Loop um mode collapse zu minimieren

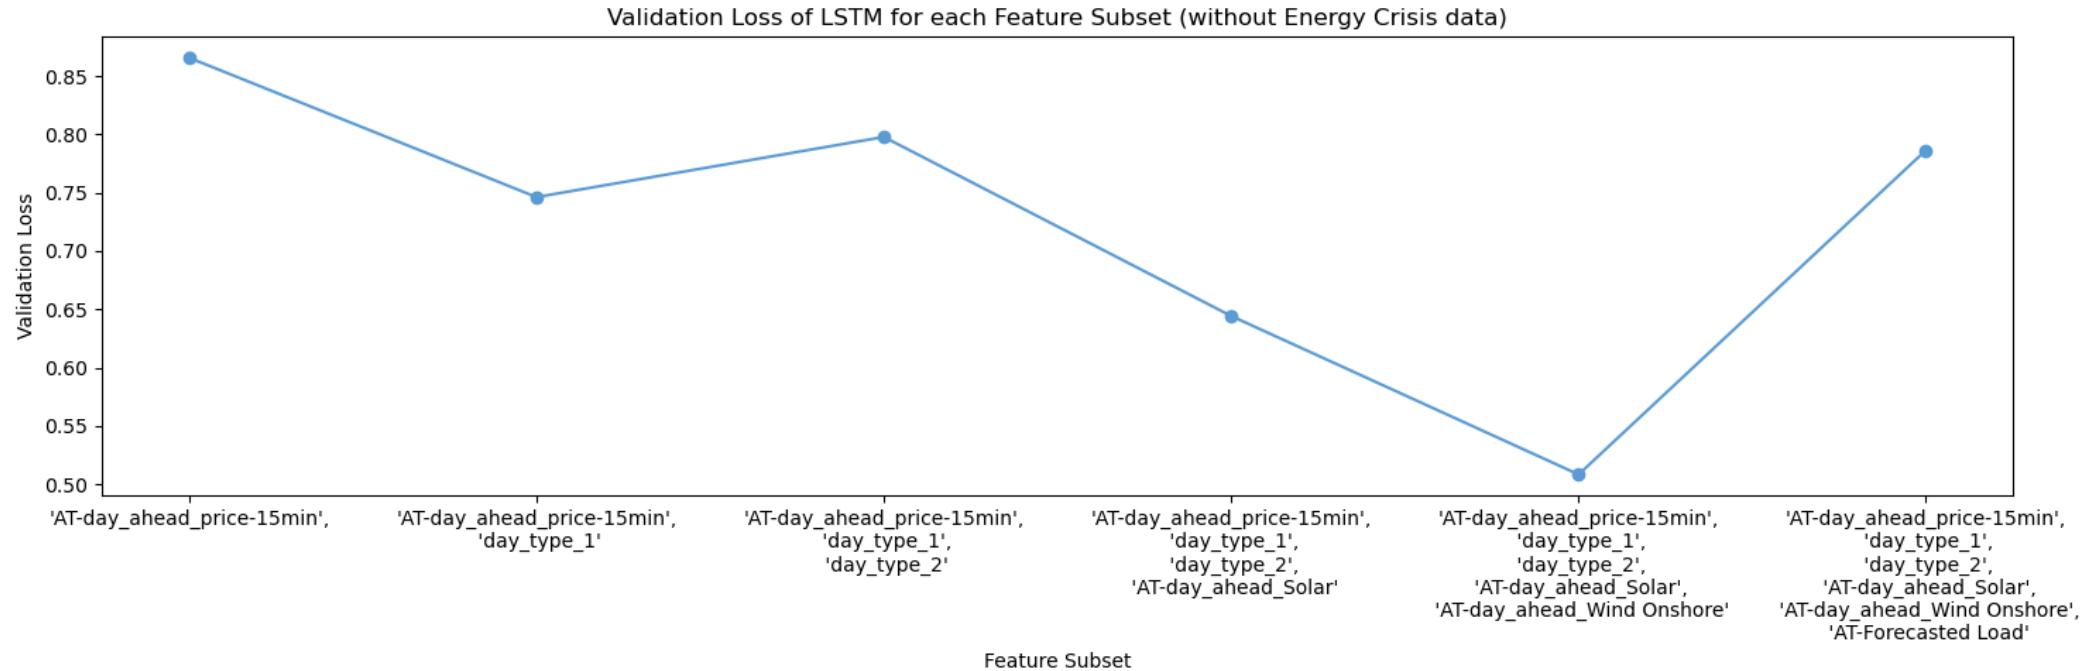


Architecture of cTSGAN. Source: [Lu, 2022]

Eingabe- und Ausgabe-Daten



Feature Selection (Forward Feature Selection)



Evaluierung

- Standard-Metriken
 - Deterministische Modelle: RMSE, MSE, ...
 - Probabilistische Modelle: Log-Likelihood, Continuously Ranked Probability Score (CRPS), Coverage, Sharpness, Wasserstein-Distanz, ...
- Optimierungsansatz:
 - Identifiziere Zeitschritt mit höchstem und Zeitschritt mit niedrigstem prognostiziertem Preis:
 - $t_1 = \operatorname{argmax}[\text{Preis}_{\text{Prognose}}(t)]$
 - $t_2 = \operatorname{argmin}[\text{Preis}_{\text{Prognose}}(t)]$
 - Berechne tatsächliche Preise an jeweiligen Zeitschritten
 - Ertrag = $\text{Preis}_{\text{Tatsächlich}}(t_1) - \text{Preis}_{\text{Tatsächlich}}(t_2)$

Optimierung

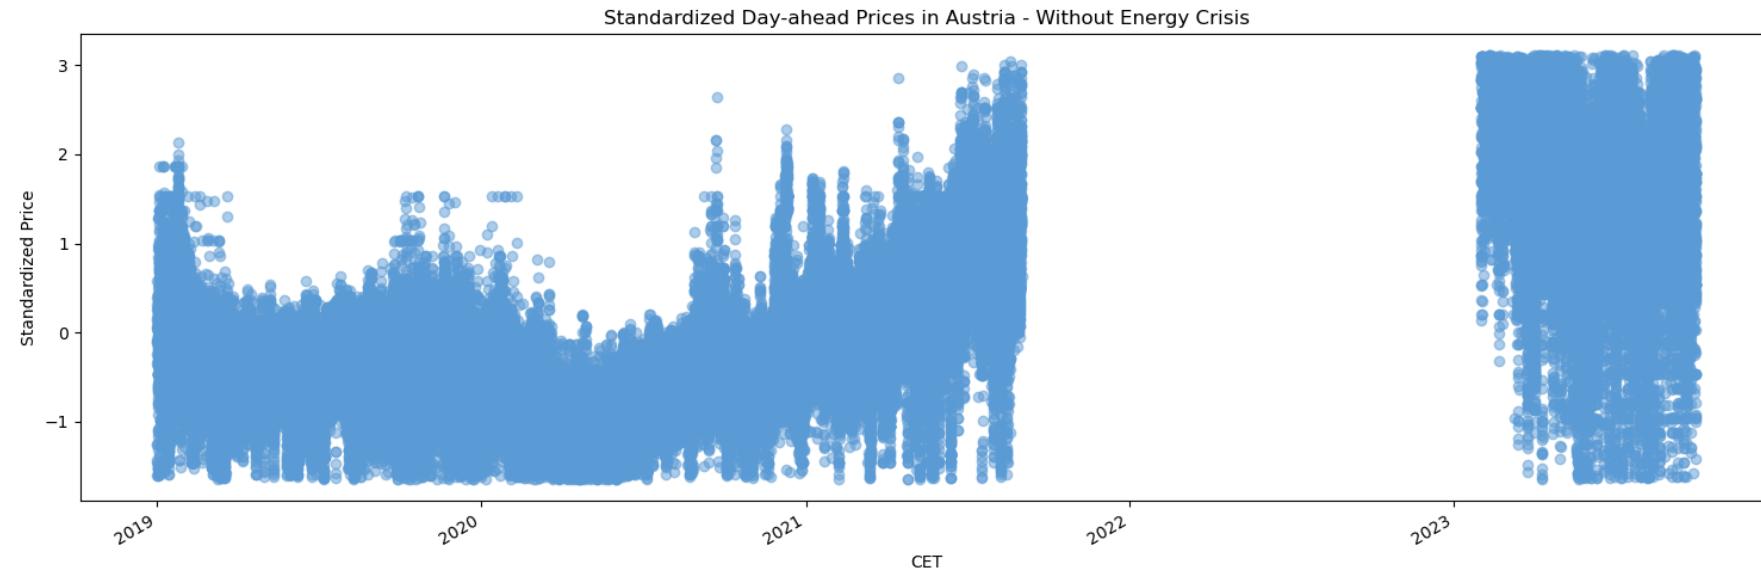
- Variante für Punktschätzer nimmt bei probabilistischen Prognose den Mittelwert der Samples
- Für probabilistische Modelle verschiedene Optimierungsstrategien
 - Pessimistisch: niedriges Perzentil der Preis-Deltas nehmen
 - Score: Verschiedene Gewichtung auf Mittelwert und Varianz
 - Probability: Nur Delta nehmen wenn jedes Delta im Sample Gewinnwahrscheinlichkeit von 1 hat

Optimierung

- Mittelwert-Ansatz:
 - Bei probabilistischen Modellen: berechne Mittelwert der Prognose-Samples
 - Für alle Zeitschritte t_1, t_2 in T berechne (prognostizierte) Preisdifferenz:
 $\Delta(t_1, t_2) = \text{Preis_Prognose}(t_1) - \text{Preis_Prognose}(t_2)$
 - Nimm t_1, t_2 von größtem Δ : $(t_1, t_2) = \text{argmax}_{\{(t_1, t_2) \text{ in } T \times T\}}(\Delta(t_1, t_2))$
 - Berechne Ertrag mit echten Preisdaten:
 $\text{Ertrag} = \text{Preis_Tatsächlich}(t_1) - \text{Preis_Tatsächlich}(t_2)$
- Pessimistischer Ansatz (nur für probabilistische Modelle möglich):
 - Für alle Zeitschritte t_1, t_2 in T und alle Samples i in $\{1, \dots, n\}$ berechne (prognostizierte) Preisdifferenz: $\Delta_i(t_1, t_2) = \text{Preis_Prognose}_i(t_1) - \text{Preis_Prognose}_i(t_2)$
 - Berechne niedriges Quantil Δ_q der $\{\Delta_i\}$ und Nimm t_1, t_2 von größtem Δ_q :
 $(t_1, t_2) = \text{argmax}_{\{(t_1, t_2) \text{ in } T \times T\}}(\Delta_q(t_1, t_2))$
 - Berechne Ertrag mit echten Preisdaten:
 $\text{Ertrag} = \text{Preis_Tatsächlich}(t_1) - \text{Preis_Tatsächlich}(t_2)$

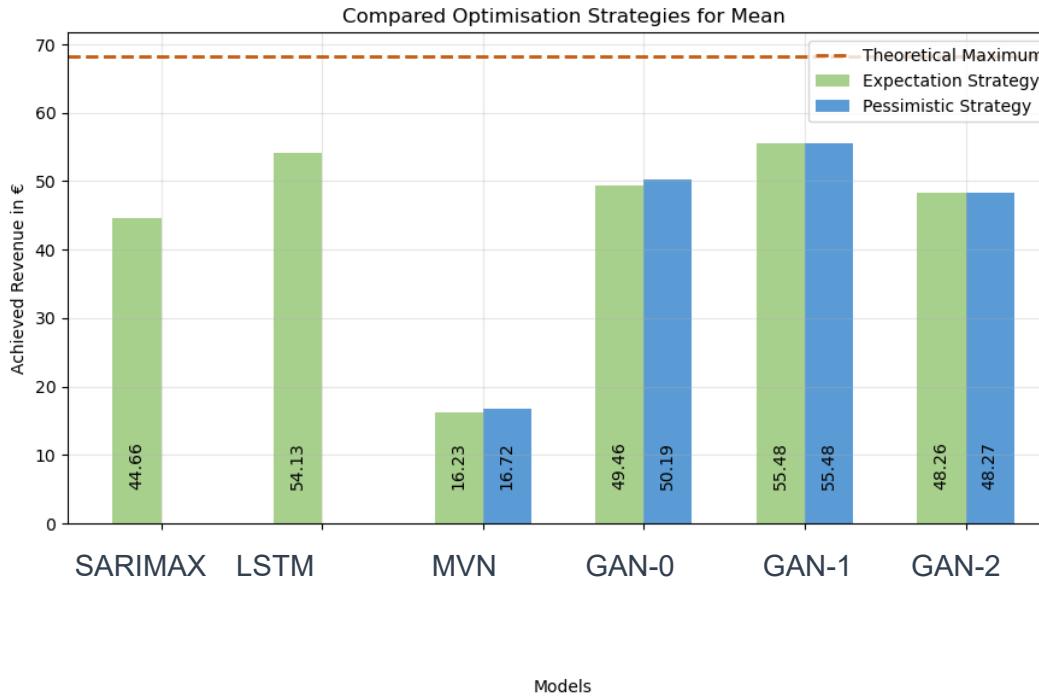
Daten Peak Shaving & Standardisierung

- Day-ahead Preise von 2019 bis Mitte 2024 [ENTSO-E transparency platform]

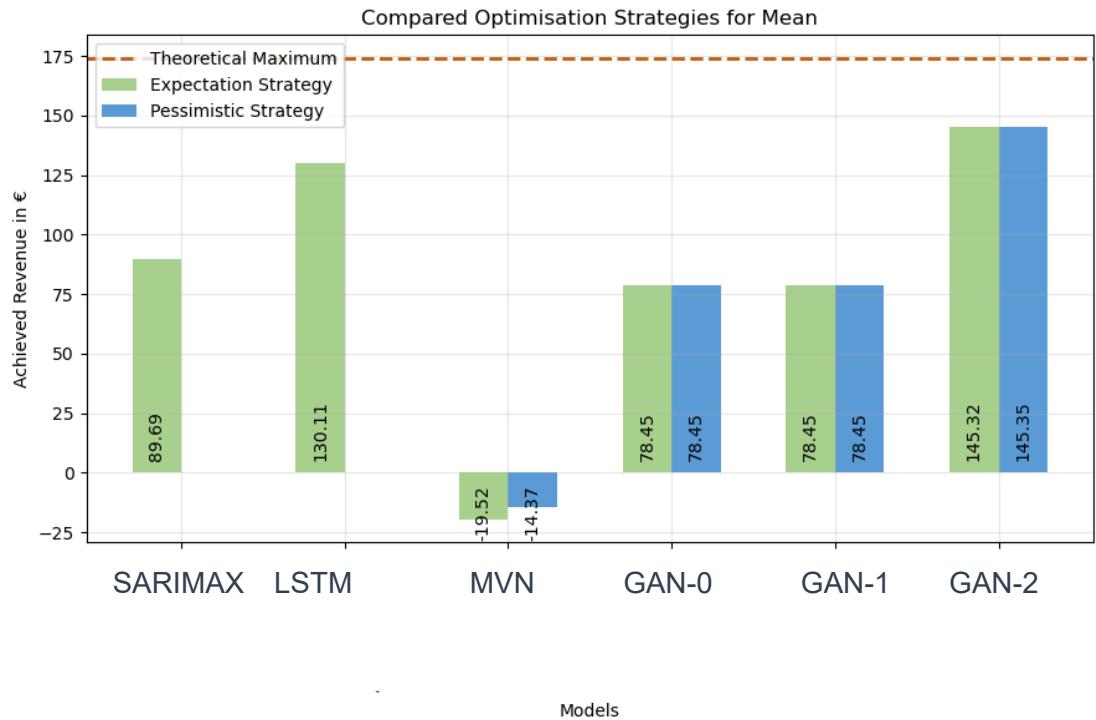


Andere Trainingsdaten

- Nur vor Energiekrise:

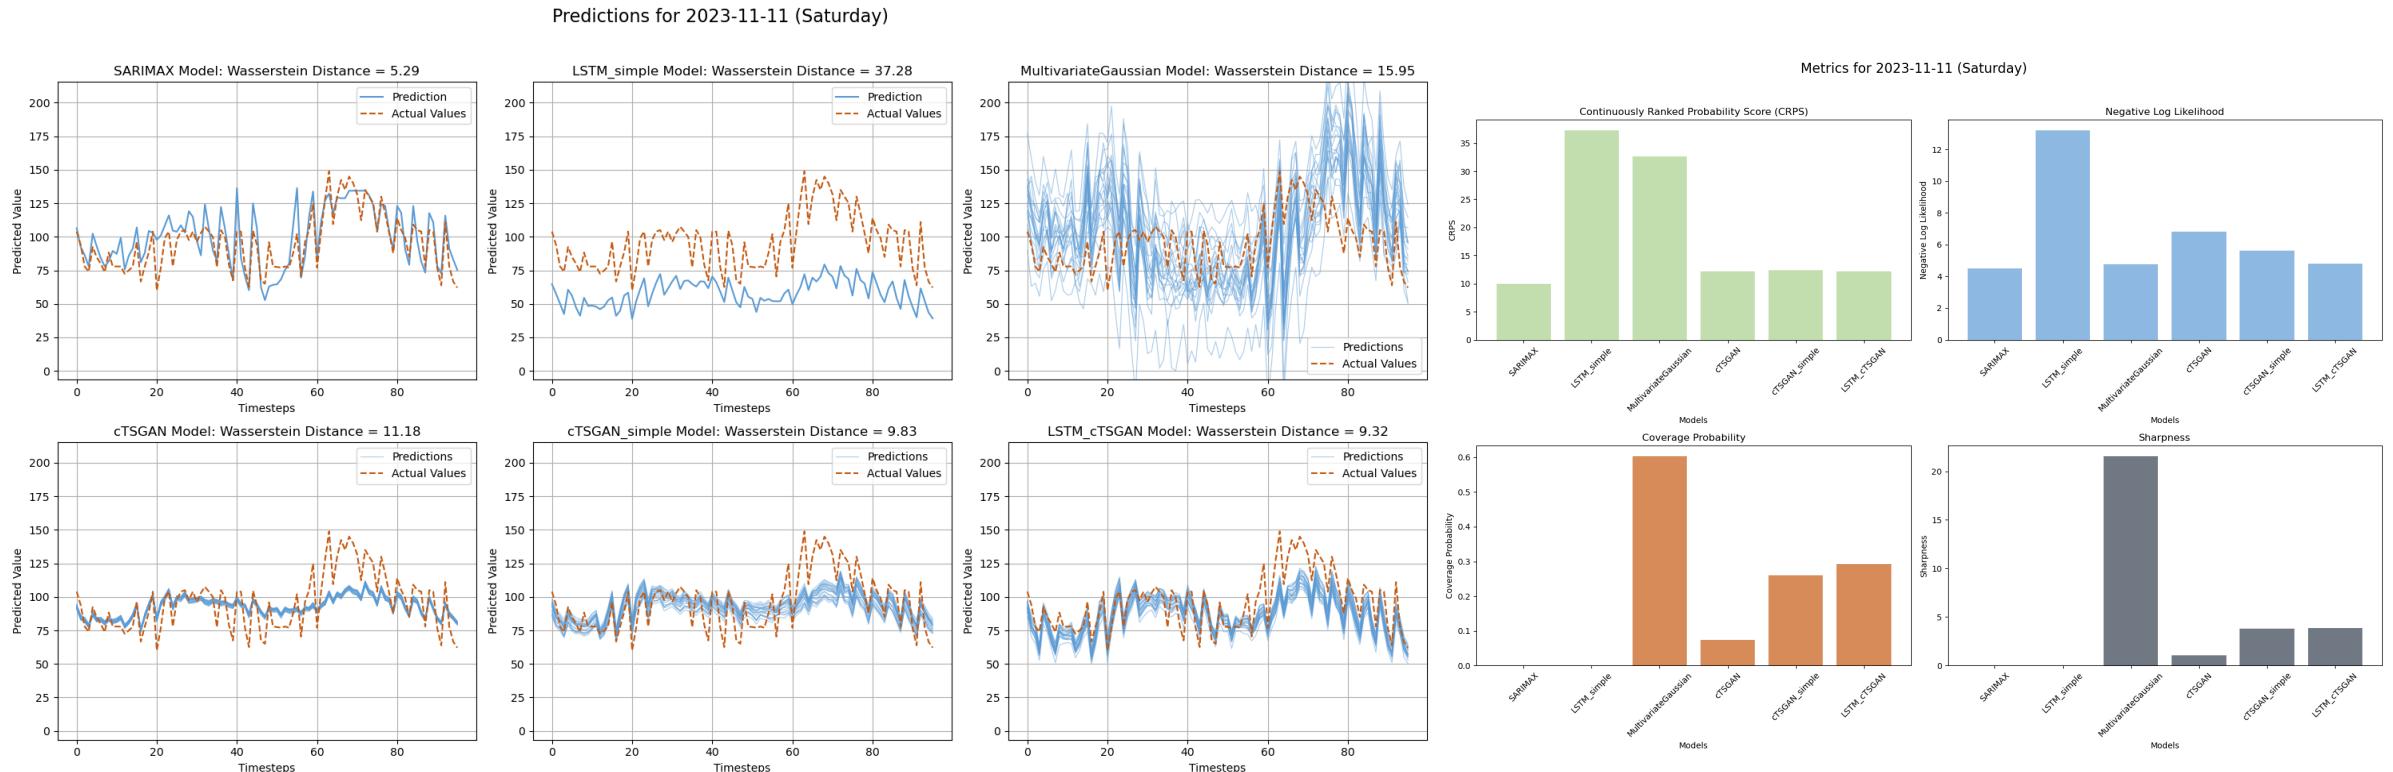


- Nur nach Energiekrise:



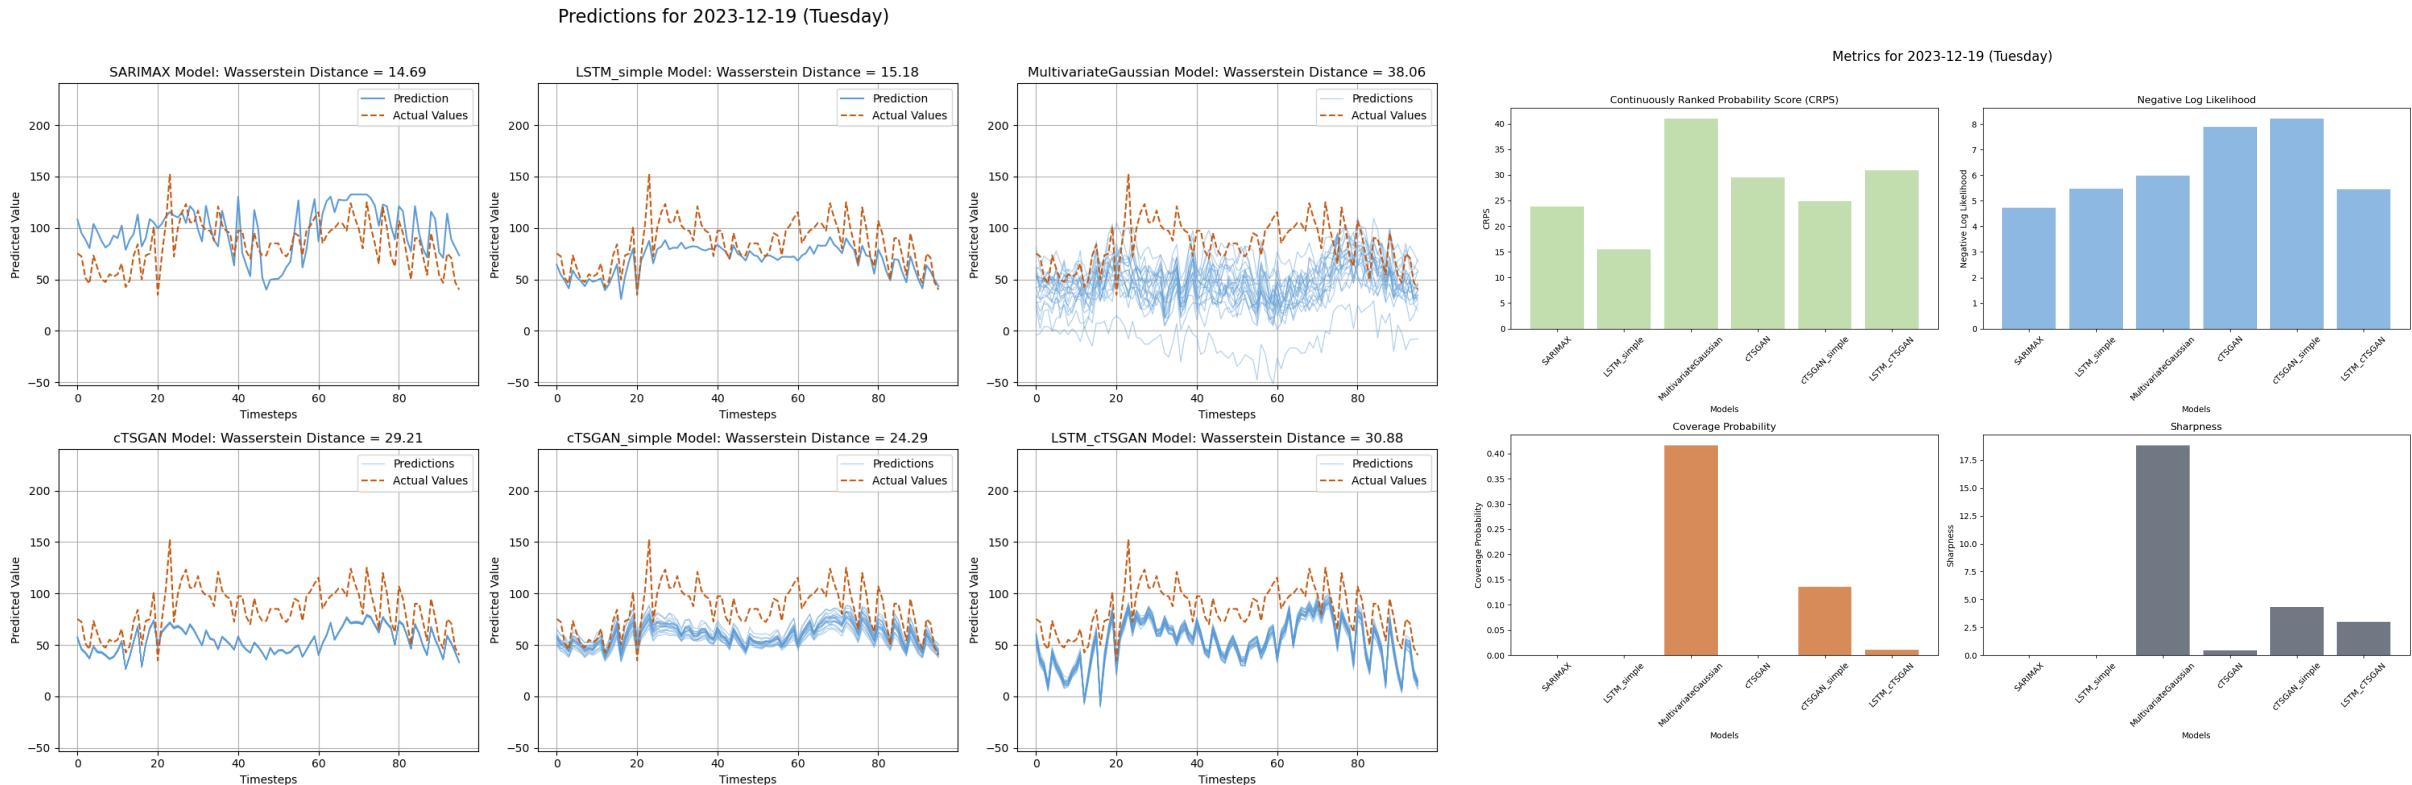
Ergebnisse

Beispiel: 11.11.2023 (Samstag)



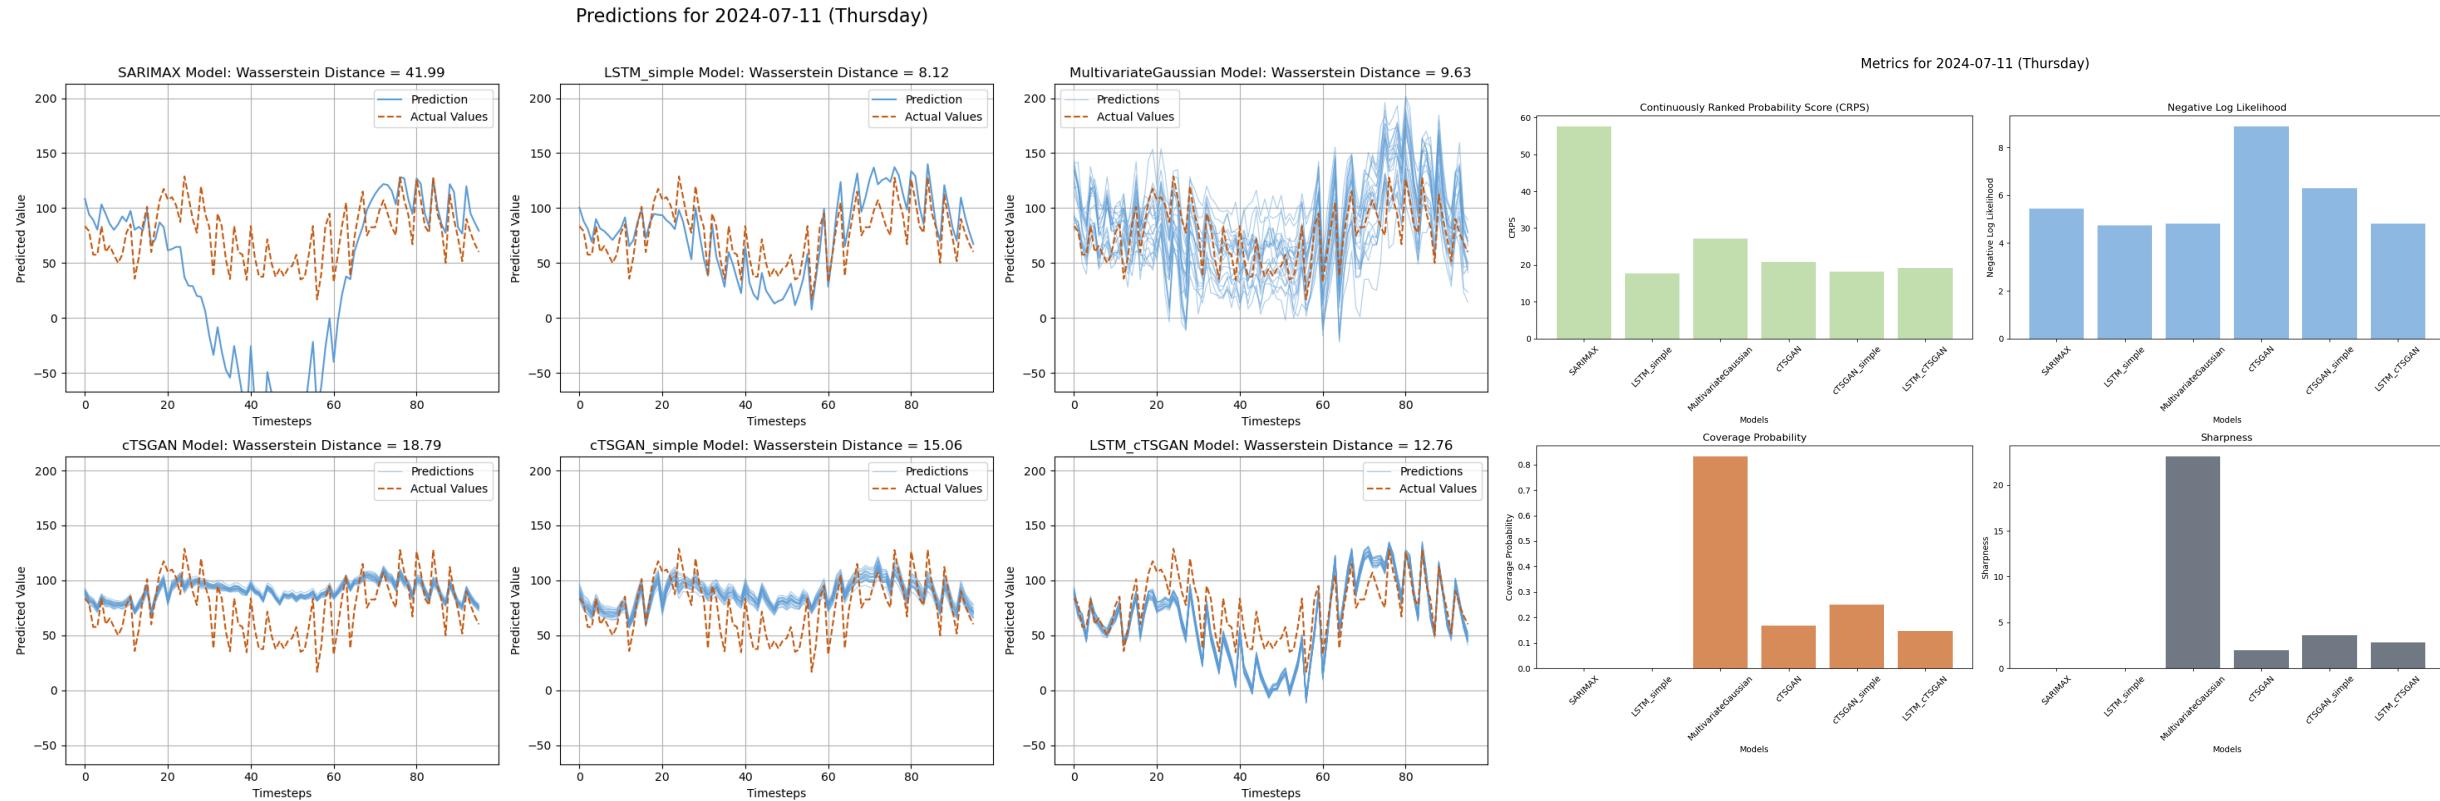
Ergebnisse

Beispiel: 19.12.2023 (Dienstag)



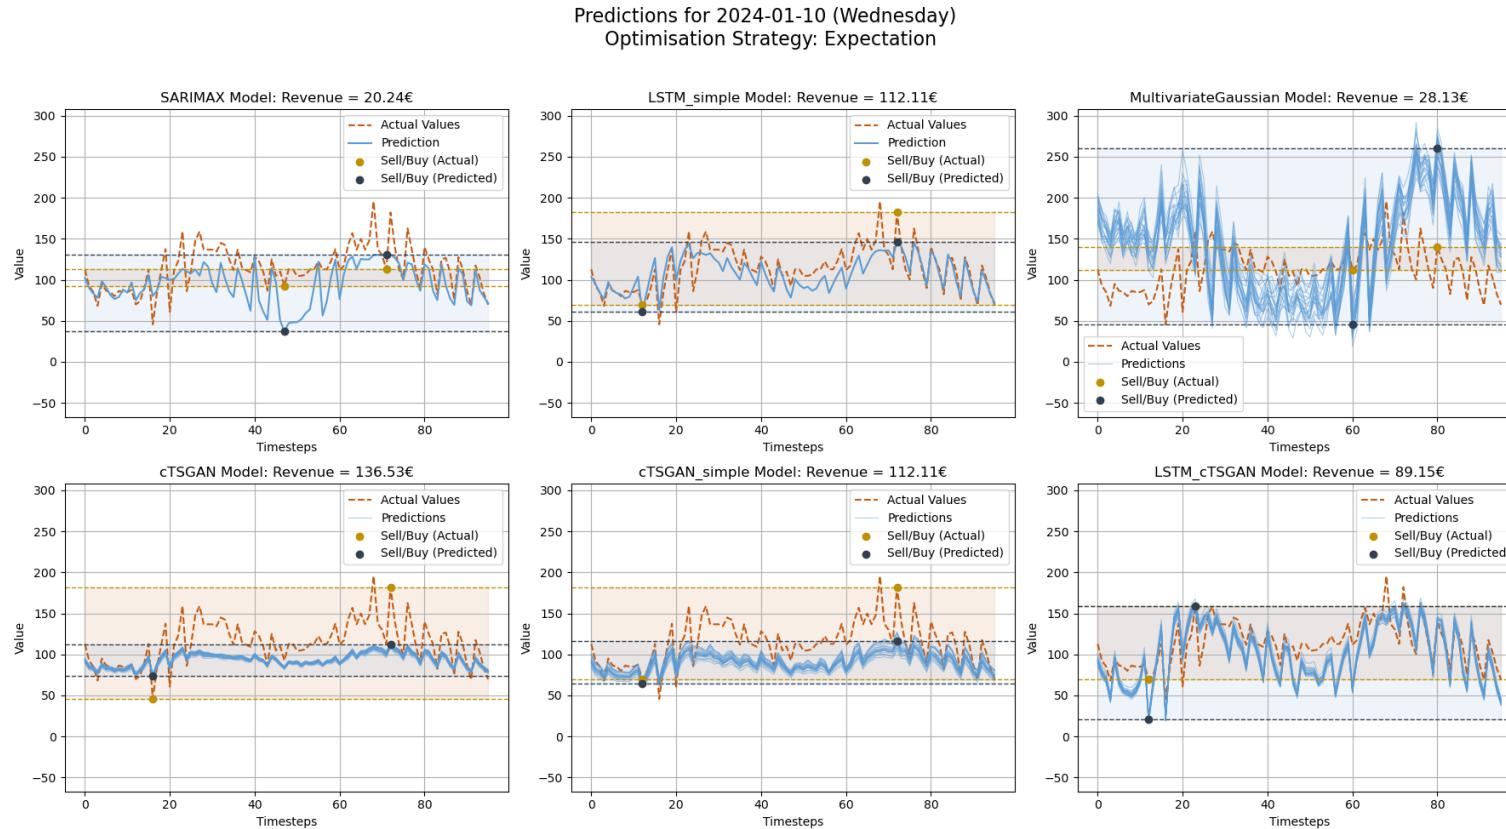
Ergebnisse

Beispiel: 11.7.2024 (Donnerstag)

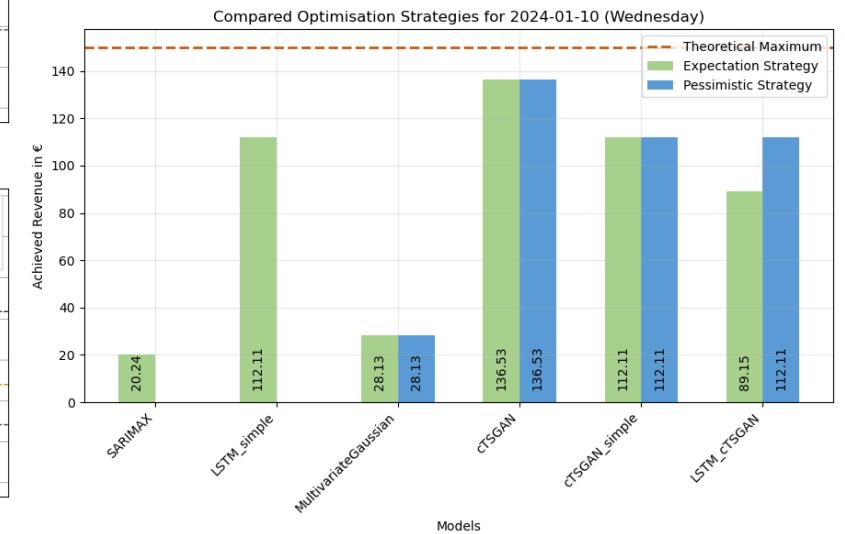


Optimierung

Beispiel: 10.1.2024 (Mittwoch)

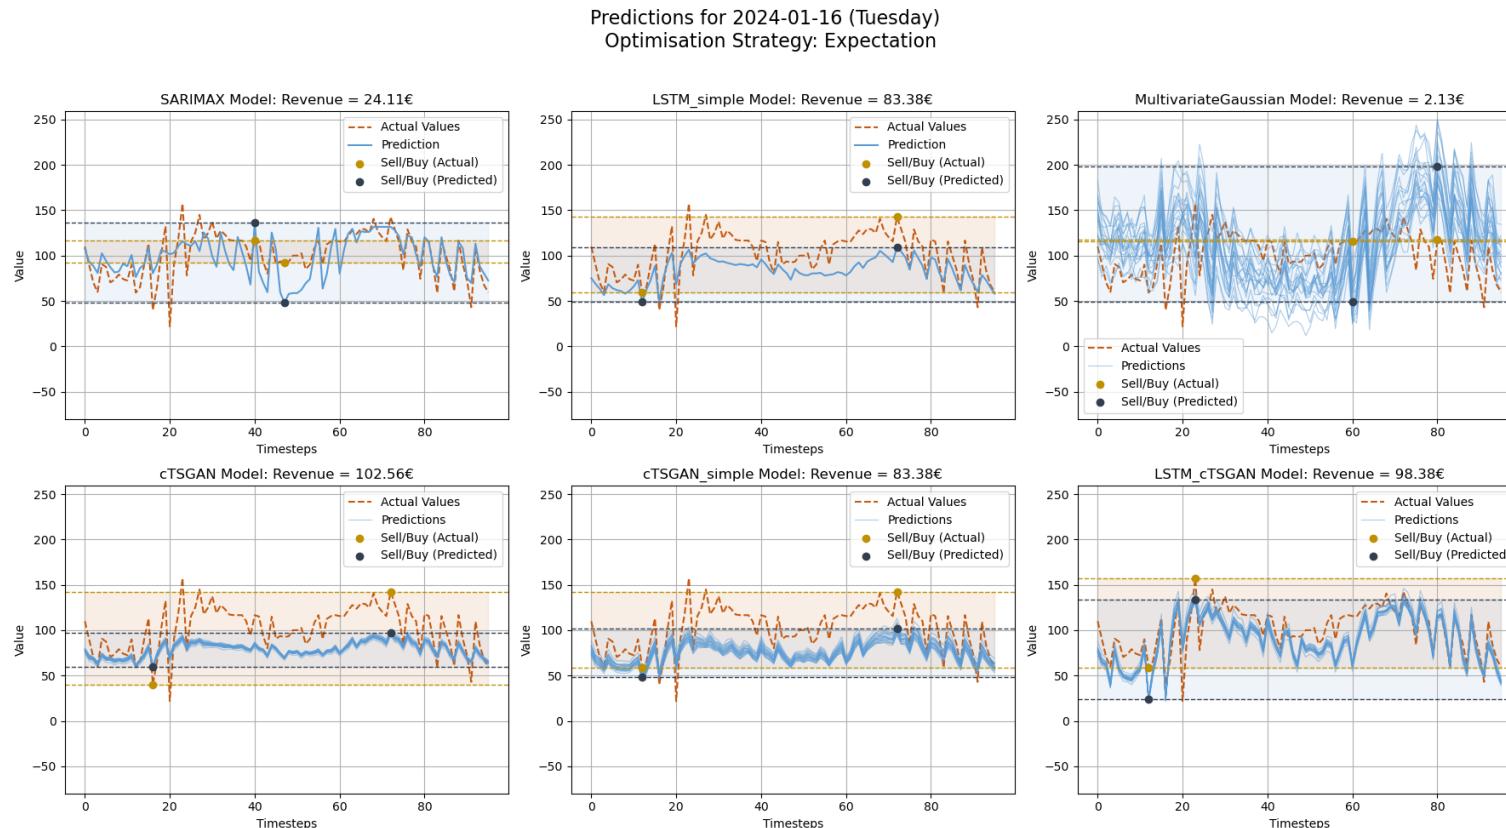


- $t_1 = \text{argmax}[\text{Preis}_{\text{Prognose}}(t)]$
- $t_2 = \text{argmin}[\text{Preis}_{\text{Prognose}}(t)]$
- Ertrag = Preis_{Tatsächlich}(t_1) - Preis_{Tatsächlich}(t_2)

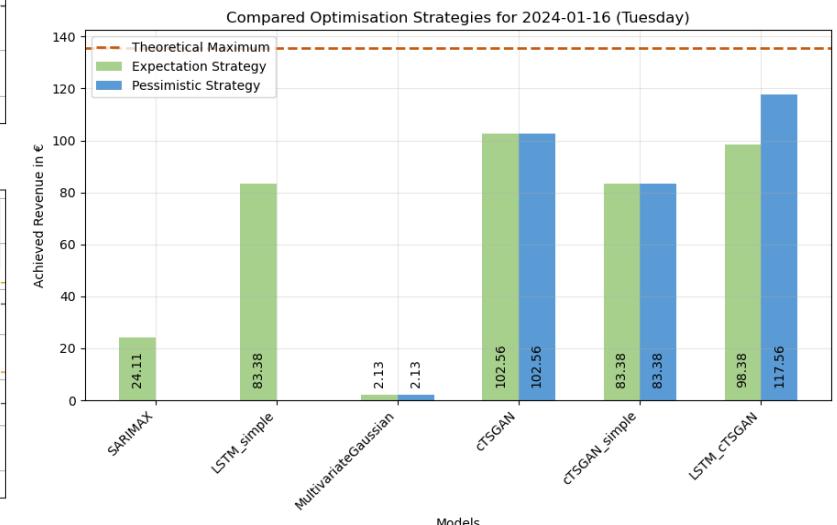


Ergebnisse: Optimierung

Beispiel: 16.1.2024 (Dienstag)



- $t_1 = \text{argmax}[\text{Preis}_{\text{Prognose}}(t)]$
- $t_2 = \text{argmin}[\text{Preis}_{\text{Prognose}}(t)]$
- Ertrag = $\text{Preis}_{\text{Tatsächlich}}(t_1) - \text{Preis}_{\text{Tatsächlich}}(t_2)$



Ergebnisse: Optimierung Energiekrise als Test-Daten

